Aproximação de funções – o método dos mínimos quadrados

O estudo do tópico interpolação polinomial fornece uma maneira de aproximarmos uma função por um polinômio, com a característica que este coincida com o valor da função em alguns pontos, isto é, $P(x_i)=f(x_i)$ $i=0,1,...,n$, e dizemos que $P(x)$ interpola a função $f(x)$ nos pontos $x_0, x_1, ..., x_n$. Assim, $P(x)$ é uma aproximação para a função $f(x)$.

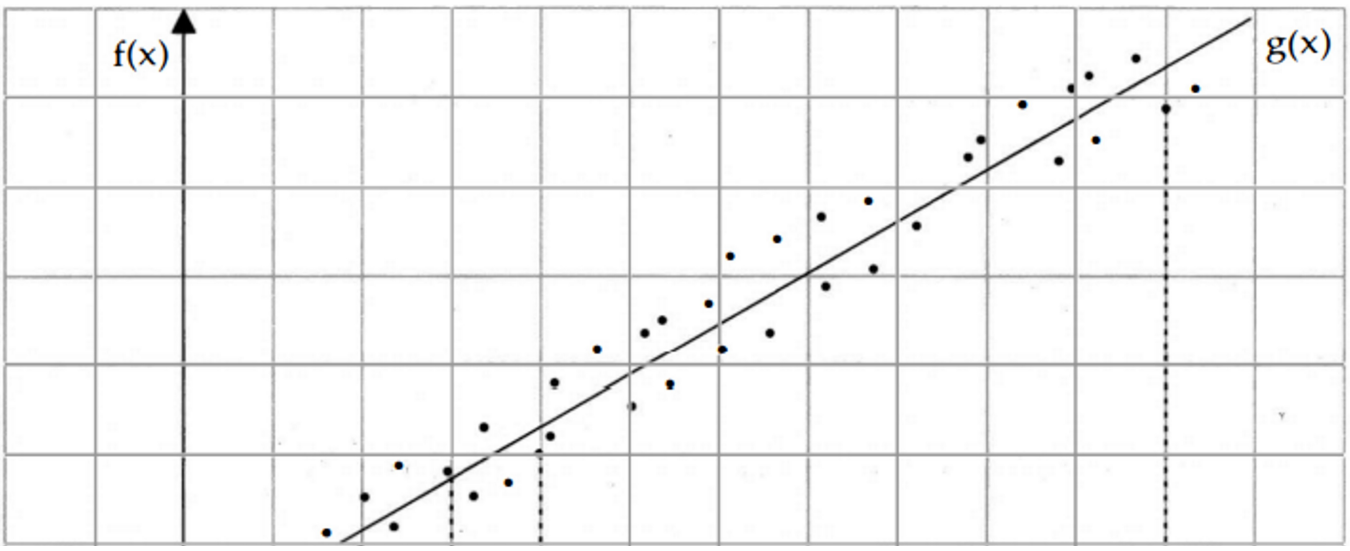
Apresentamos, nesta seção, uma forma alternativa para aproximar uma função $f(x)$ usando o método dos mínimos quadrados, o qual consiste em, conhecidos os valores de $f(x)$ em m pontos, determinar uma função $g(x)$ que melhor se aproxime de $f(x)$. Esta melhor aproximação será definida a seguir, e a função $g(x)$ pode ser uma combinação de funções polinomiais, exponenciais logarítmicas, trigonométricas etc.

1 *Caso discreto*

Inicialmente, consideramos o caso em que a função $f(x)$ é definida em um conjunto discreto, isto é, a função é conhecida em m pontos, geralmente obtidos em experimentos, conforme a tabela:

x	x_1	x_2	...	x_m
f(x)	$f(x_1)$	$f(x_2)$	...	$f(x_m)$

Graficamente, temos a disposição dos pontos obtidos no experimento na Figura 4.6:



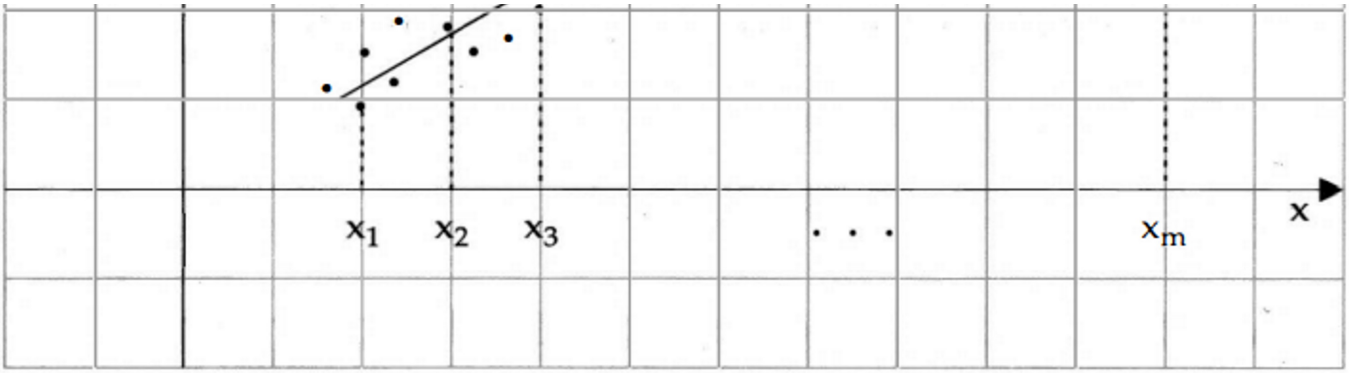


Figura 4.6

Observando a disposição dos pontos $(x_i, f(x_i))$ $i = 1, ..., m$ na Figura 4.6, vemos que g(x) possui o comportamento de uma reta, isto é, um polinômio de grau 1:

$$g(x) = a_1 g_1(x) + a_2 g_2(x) = a_1 x + a_2$$

com $g_1(x) = x$ e $g_2(x) = 1$. Assim, escolhemos uma família de funções as quais dependem dos parâmetros a_1 e a_2.

O problema agora consiste em determinar os parâmetros a_1 e a_2 de modo que a função g(x) se ajuste melhor aos dados da tabela. Para falar em "melhor ajuste", temos de ter um critério para a escolha dos parâmetros a_1 e a_2, isto é, ter uma medida para o erro cometido nesta aproximação.

Definição

Definimos $e(x_i) = f(x_i) - g(x_i)$ como o erro ou desvio cometido numa aproximação de uma função f(x) por uma função g(x), nos pontos x_i $i = 1, ..., m$.

Desta forma, desejamos determinar uma função g(x) de modo que nos pontos x_i $i = 1, ..., m$ os desvios sejam "pequenos". Neste caso, é tentador desejar que a soma dos erros seja mínima, isto é, que $\sum_{i=1}^{m} e(x_i)$ seja mínima. Entretanto, este fato não traduz que g(x) seja uma "boa" aproximação para a função f(x), como podemos observar na Figura 4.7, em que a função g(x) que melhor se aproxima de f(x) é a reta r_1, que passa pelos pontos dados e $\sum_{i=1}^{2} e(x_i) = 0$.

No entanto, quando tomamos a reta r_2, temos também que $\sum_{i=1}^{2} e(x_i) = 0$ e esta reta não é uma "boa" aproximação para a função f(x), embora a soma dos erros seja zero, o que não significa que os erros sejam nulos, pois somamos grandezas numéricas com sinais opostos, podemos notar que $e(x_1) > 0$ e $e(x_2) < 0$ para a reta r_2.

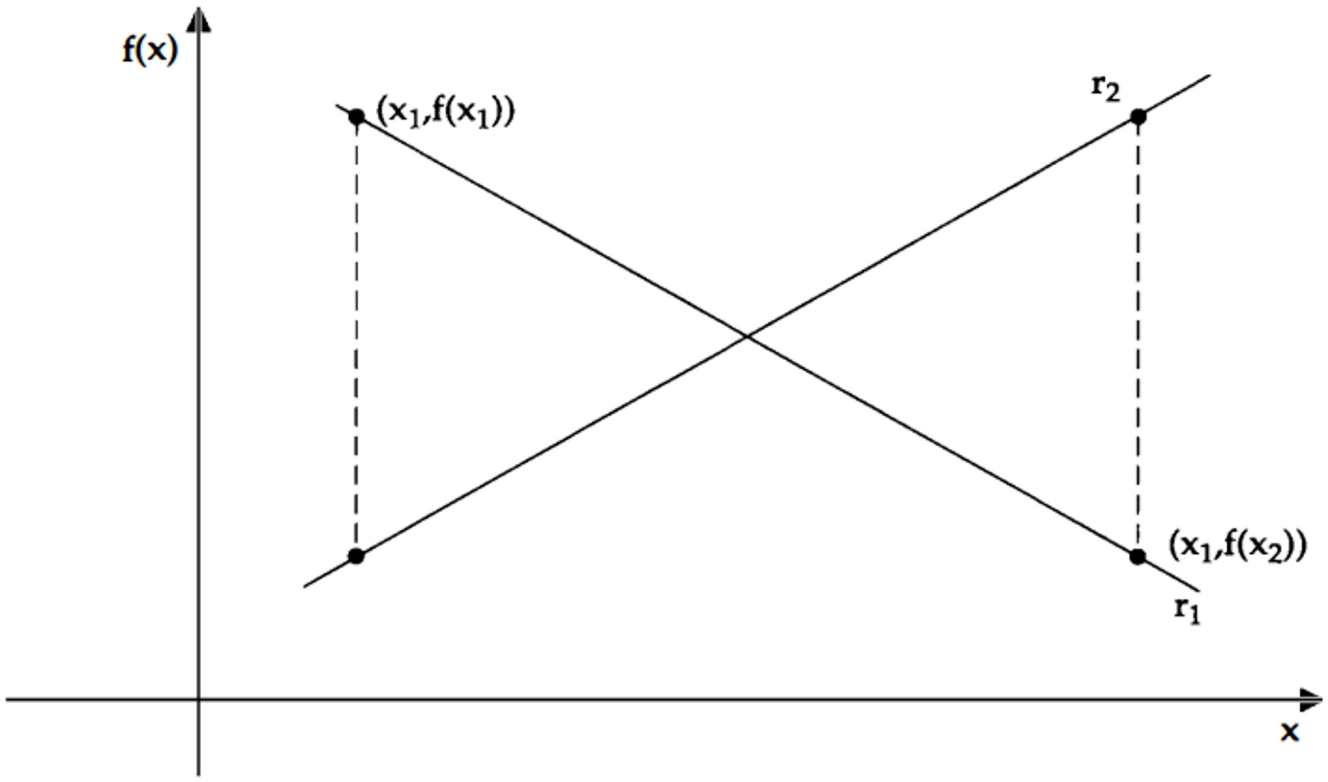


Figura 4.7

Um critério para obter $e(x_i)$ i = 1, ..., m pequenos em todos os pontos da tabela seria considerar a soma $\sum_{i=1}^{m}|e(x_i)|$ mínima, porém este critério acarreta dificuldades de resolução, pois a função valor absoluto não é diferenciável na origem.

Uma maneira para contornar esses problemas consiste em considerar uma medida para o erro da seguinte forma:

$$\text{minimizar} \sum_{i=1}^{m} e(x_i)^2 = \text{minimizar} \sum_{i=1}^{m} (f(x_i) - g(x_i))^2$$

Assim, considerando o exemplo da Figura 4.6, desejamos encontrar uma função $g(x) = a_1x + a_2$ que melhor se aproxime da função f(x), de forma que $E(a_1, a_2) = \sum_{i=1}^{m} (e(x_i))^2$ seja mínimo. Do cálculo diferencial, se a função $E(a_1, a_2)$ possui um ponto de mínimo, então suas derivadas parciais devem ser nulas, isto é,

$$\frac{\partial E}{\partial a_1} = 0 \qquad \frac{\partial E}{\partial a_2} = 0$$

Derivando $E(a_1, a_2)$ com relação à variável "a_1", temos:

$$\frac{\partial E}{\partial a_1} = \frac{\partial}{\partial a_1}\left(\sum_{i=1}^{m} (e(x_i))^2\right) = \frac{\partial}{\partial a_1}\left(\sum_{i=1}^{m} (a_1x_i + a_2 - f(x_i))^2\right) =$$

$$= \sum_{i=1}^{m} 2(a_1x_i + a_2 - f(x_i))x_i =$$

$$= 2\left[a_1 \sum_{i=1}^{m} x_i^2 + a_2 \sum_{i=1}^{m} x_i\right] - 2\left[\sum_{i=1}^{m} x_i\, f(x_i)\right] = 0$$

Assim, temos:

i) $$\left(\sum_{i=1}^{m} x_i^2\right) a_1 + \left(\sum_{i=1}^{m} x_i\right) a_2 = \sum_{i=1}^{m} x_i\ f(x_i)$$

Derivando $E(a_1, a_2)$ com relação à variável a_2 temos:

$$\frac{\partial}{\partial a_2} = \frac{\partial}{\partial a_2}\left(\sum_{i=1}^{m}(e(x_i))^2\right) = \frac{\partial}{\partial a_2}\left(\sum_{i=1}^{m}(a_1x_i + a_2 - f(x_i))^2\right) =$$

$$= \sum_{i=1}^{m} 2(a_1x_i + a_2 - f(x_i)) =$$

$$= 2\left[a_1\sum_{i=1}^{m}x_i + m(a_2) - \sum_{i=1}^{m}f(x_i)\right] = 0$$

Assim, temos:

ii) $$\left(\sum_{i-1}^{m}x_i\right)a_1 + m\,a_2 = \sum_{i=1}^{m} f(x_i)$$

Portanto, os parâmetros a_1 e a_2 que minimizam o erro $E(a_1, a_2)$ necessariamente satisfazem o seguinte sistema de equações lineares:

$$\begin{cases} \left(\sum_{i=1}^{m}x_i^2\right)a_1 + \left(\sum_{i=1}^{m}x_i\right)a_2 = \sum_{i=1}^{m}x_i\ f(x_i)) \\ \left(\sum_{i=1}^{m}x_i\right)a_1 \quad + \quad m\,a_2 \quad = \sum_{i=1}^{m} f(x_i) \end{cases}$$

O sistema de equações obtido é chamado sistema de equações normais, o qual pode ser resolvido por qualquer método visto anteriormente. Particularmente, o método de Cholesky pode ser aplicado, pois o sistema de equações normais possui a matriz A do sistema simétrica e definida positiva.

Prova-se que a solução do sistema de equações normais nos parâmetros a_1 e a_2, de fato minimizam a soma dos quadrados dos erros.

Exemplo

Seja f(x) tabelada como segue:

x_i	0	1	2	3	4
$f(x_i)$	0.98	–3.01	–6.99	–11.01	–15

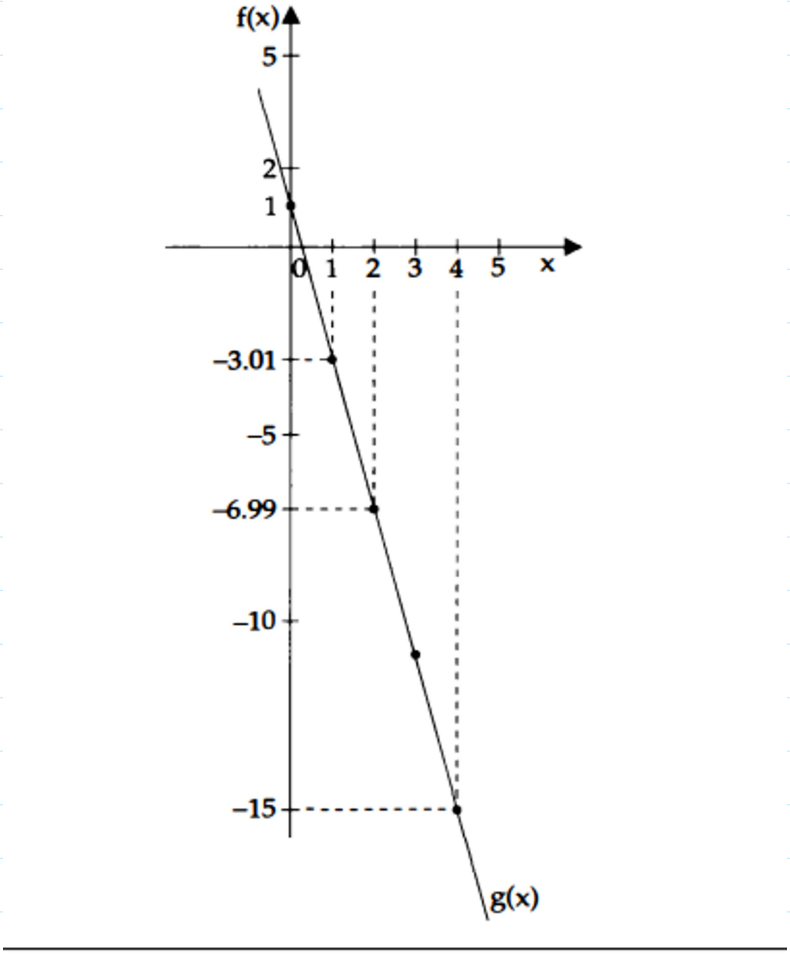


Figura 4.8

Observando o gráfico da Figura 4.8, vemos que os dados possuem o comportamento linear. Usando o método dos mínimos quadrados, determinamos dentre todas as retas $g(x) = a_1x + a_2$ aquela que melhor se ajusta aos dados.

$$\begin{bmatrix} \sum_{k=1}^{5} x_i^2 & \sum_{k=1}^{5} x_i \\ \sum_{k=1}^{5} x_i & 5 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{k=1}^{5} f(x_i)x_i \\ \sum_{k=1}^{5} f(x_i) \end{bmatrix}$$

	x_i	$f(x_i)$	x_i^2	$f(x_i)x_i$
	0	0.98	0	0.00
	1	–3.01	1	–3.01
	2	–6.99	4	–13.98
	3	–11.01	9	–33.03
	4	–15.00	16	–60.00
Σ	10	–35.03	30	–110.02

Assim, temos o seguinte sistema de equações lineares:

$$\begin{bmatrix} 30 & 10 \\ 10 & 5 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} -110.02 \\ -35.03 \end{bmatrix}$$

Usando o método de eliminação de Gauss, temos:

$$\begin{cases} a_1 = -3.9960 \\ a_2 = 0.9860 \end{cases}$$

Portanto, $g(x) = -3.9960\,x + 0.9860$

Podemos ter dados experimentais onde seja necessário aproximar a função f(x) por um polinômio de grau 2, isto é, uma parábola:

$$g(x) = a_1 g_1(x) + a_2 g_2(x) + a_3 g_3(x) = a_1 x^2 + a_2 x + a_3$$

com $g_1(x) = x^2$, $g_2(x) = x$ e $g_3(x) = 1$

Generalizando este procedimento, escrevemos g(x) como uma combinação linear de funções como segue:

$$g(x) = a_1 g_1(x) + a_2 g_2(x) + \ldots + a_n g_n(x)$$

com $g_i(x)$ sendo funções escolhidas.

Procedendo de maneira análoga ao caso do ajuste linear, a reta, podemos determinar os parâmetros a_i i=1, ..., n de forma que o erro $\sum_{i=1}^{m} e(x_i)^2$ seja mínimo.

Assim, temos:

$$\frac{\partial E}{\partial a_1}=0\Leftrightarrow(\sum_{i=1}^{m}g_1(x_i)g_1(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_1(x_i))a_2+\ldots+$$
$$+\sum_{i=1}^{m}g_n(x_i)g_1(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_1(x_i)$$
$$\frac{\partial E}{\partial a_2}=0\Leftrightarrow(\sum_{i=1}^{m}g_1(x_i)g_2(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_2(x_i))a_2+\ldots+$$
$$+(\sum_{i=1}^{m}g_n(x_i)g_2(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_2(x_i)$$
$$\vdots$$
$$\frac{\partial E}{\partial a_n}=0\Leftrightarrow(\sum_{i=1}^{m}g_1(x_i)g_n(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_n(x_i))a_2+\ldots+$$
$$+(\sum_{i=1}^{m}g_n(x_i)g_n(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_n(x_i)$$

Portanto, para determinar os parâmetros a_i $i=1, \ldots, n$, devemos resolver o seguinte sistema de equações lineares:

$$\begin{cases}(\sum_{i=1}^{m}g_1(x_i)g_1(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_1(x_i))a_2+\ldots+\sum_{i=1}^{m}g_n(x_i)g_1(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_1(x_i)\\(\sum_{i=1}^{m}g_1(x_i)g_2(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_2(x_i))a_2+\ldots+(\sum_{i=1}^{m}g_n(x_i)g_2(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_2(x_i)\\\quad\vdots\\(\sum_{i=1}^{m}g_1(x_i)g_n(x_i))a_1+(\sum_{i=1}^{m}g_2(x_i)g_n(x_i))a_2+\ldots+(\sum_{i=1}^{m}g_n(x_i)g_n(x_i))a_n=\sum_{i=1}^{m}f(x_i)g_n(x_i)\end{cases}$$

O sistema de equações lineares obtido é denominado sistema de equações normais, o qual pode ser resolvido por qualquer método visto anteriormente. Resolvido este sistema, determinamos os parâmetros a_i $i=1, \ldots, n$ e conseqüentemente a função $g(x) = a_1g_1(x) + \ldots + a_ng_n(x)$ que melhor se ajusta à função $f(x)$ nos pontos $x_1 \ldots x_m$ no sentido dos mínimos quadrados.

Exemplo

Considere uma função f(x) definida conforme tabela:

x	–2	–1	0	1	2	3
f(x)	19.01	3.99	–1.00	4.01	18.99	45.00

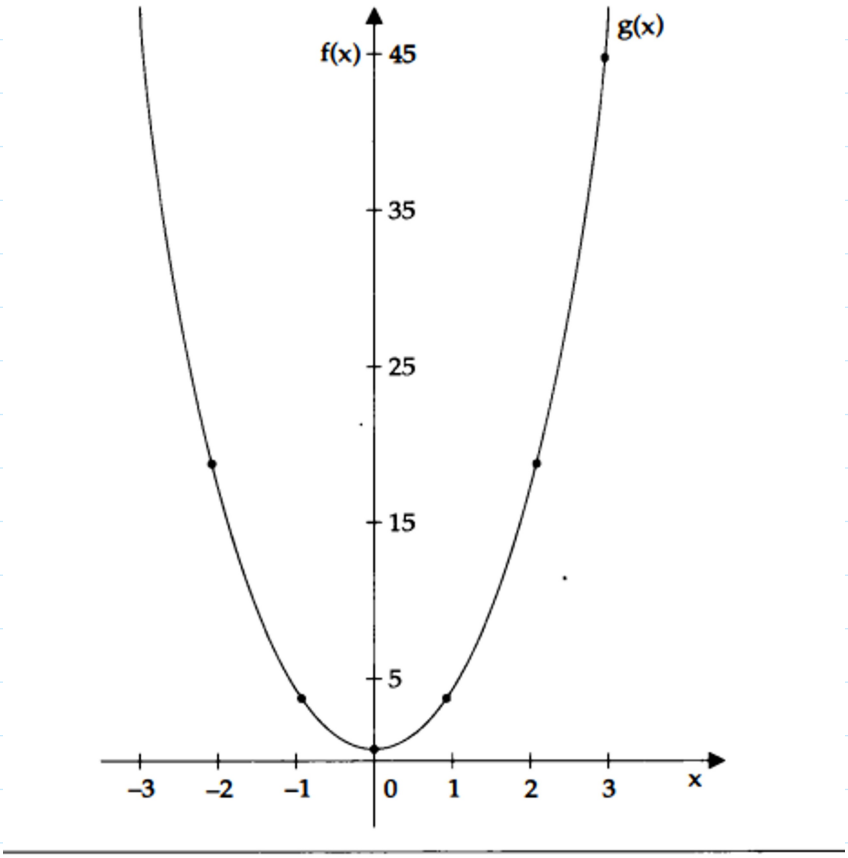


Figura 4.9

Observando a Figura 4.9, vemos que a função possui o comportamento de uma parábola, polinômio de grau 2.

Assim, tomamos $g(x) = a_1x^2 + a_2x + a_3$, isto é, $g_1(x) = x^2$, $g_2(x) = x$, $g_3(x) = 1$, e determinamos os parâmetros a_1, a_2, e a_3 de modo que g(x) se ajuste aos dados da tabela no senso dos mínimos quadrados.

Temos o sistema de equações normais:

$$\begin{bmatrix} \sum_{i=1}^{6} x_i^4 & \sum_{i=1}^{6} x_i^3 & \sum_{i=1}^{6} x_i^2 \\ \sum_{i=1}^{6} x_i^3 & \sum_{i=1}^{6} x_i^2 & \sum_{i=1}^{6} x_i \\ \sum_{i=1}^{6} x_i^2 & \sum_{i=1}^{6} x_i & 6 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{6} f(x_i)x_i^2 \\ \sum_{i=1}^{6} f(x_i)x_i \\ \sum_{i=1}^{6} f(x_i) \end{bmatrix}$$

	x_i	x_i^2	x_i^3	x_i^4	$f(x_i)$	$x_i f(x_i)$	$x_i^2 f(x_i)$
	–2	4	–8	16	19.01	–38.02	76.04
	–1	1	–1	1	3.99	–3.99	3.99
	0	0	0	0	–1.00	0.00	0.00
	1	1	1	1	4.01	4.01	4.01
	2	4	8	16	18.99	37.98	75.96
	3	9	27	81	45.00	135.00	405.00
Σ	3	19	27	115.00	90.00	134.98	565.00

Temos o seguinte sistema de equações lineares:

$$\begin{bmatrix} 115 & 27 & 19 \\ 27 & 19 & 3 \\ 19 & 3 & 6 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} 565.00 \\ 134.98 \\ 90.00 \end{bmatrix}$$

Usando o método de eliminação de Gauss, temos:

$$\begin{cases} a_1 = 5.0893 \\ a_2 = 0.0515 \\ a_3 = -1.1403 \end{cases}$$

Portanto, $g(x) = 5.0893x^2 + 0.0515 - 1.1403$.

2 *Caso contínuo*

O método dos mínimos quadrados pode ainda ser usado para aproximar uma função f(x) contínua num intervalo [a, b], por uma combinação de funções do tipo $g(x)=a_1g_1(x)+a_2g_2(x)+...+a_ng_n(x)$, onde $g_1(x), g_2(x), ..., g_n(x)$ são funções contínuas no intervalo [a, b].

Neste caso, desejamos determinar g(x) que melhor se aproxime da função f(x), isto é, que a área entre as curvas de f(x) e g(x) seja a menor possível, dando a idéia de proximidade de duas funções, o que é representado por:

$$E(a_1, a_2, ..., a_n)=\int_a^b (f(x)-a_1g_1(x)+...+g_n(x))^2 dx$$

Assim, o problema do método dos mínimos é definido por:

Minimizar $E(a_1, a_2, ..., a_n)$

isto é, Minimizar $\int_a^b (f(x)-(a_1g_1(x)+a_2g_2(x)+...+a_ng_n(x))^2 dx$

Portanto, como anteriormente, o ponto de mínimo necessariamente satisfaz:

$$\frac{\partial E}{\partial a_1}=\frac{\partial E}{\partial a_2}=...=\frac{\partial E}{\partial a_n}=0$$

ou seja,

$$\frac{\partial E}{\partial a_i}=-2\int_a^b (f(x)-\sum_{i=0}^{m} a_kg_k(x)g_i(x))dx=0 \quad 1\le i\le m$$

Denotando o produto escalar de funções por $\langle f,g\rangle=\int_a^b f(x)g(x)dx$, temos o seguinte sistema de equações normais:

$$\begin{bmatrix} \langle g_1, g_1 \rangle & \langle g_1, g_2 \rangle & \cdots & \langle g_1, g_m \rangle \\ \langle g_2, g_1 \rangle & \langle g_2, g_2 \rangle & \cdots & \langle g_2, g_m \rangle \\ \vdots & & & \\ \langle g_m, g_1 \rangle & \langle g_m, g_2 \rangle & \cdots & \langle g_m, g_m \rangle \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \langle g_1, f \rangle \\ \langle g_1, f \rangle \\ \vdots \\ \langle g_m, f \rangle \end{bmatrix}$$

Se o determinante da matriz do sistema de equações normais for diferente de zero, então o sistema possui solução única, ou seja, existe uma única função g(x) que melhor se ajusta à função f(x). Desta forma, a solução $(a_1, a_2, ..., a_n)$ obtida na resolução deste sistema fornece a melhor $g(x) = a_1 g_1(x) + a_2 g_2(x) + ... + a_n g_n(x)$ que se aproxima da função f(x).

Observação

Se as funções escolhidas $g_i(x)$ forem linearmente independentes, então o determinante da matriz A do sistema de equações normais é diferente de zero.

Exemplo

Usando o método dos mínimos quadrados, aproxime a função $f(x)=e^{-x}$ no intervalo [1, 3] por um polinômio de grau 1 da forma $g(x)=a_1+a_2x$.

Temos:

$$g_1(x)=1,\ g_2(x)=x \text{ e } f(x) = e^{-x}$$

O sistema de equações normais é dado por:

$$\begin{bmatrix} \langle 1,1 \rangle & \langle 1,x \rangle \\ \langle 1,x \rangle & \langle x,x \rangle \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \langle 1, e^{-x} \rangle \\ \langle x, e^{-x} \rangle \end{bmatrix}$$

Assim,

$$\langle 1,1\rangle = \int_1^3 1\,dx = 1$$

$$\langle 1,x\rangle = \int_1^3 x\,dx = 4$$

$$\langle x,x\rangle = \int_1^3 x^2\,dx = 26/3 = 8.6667$$

$$\langle 1,e^{-x}\rangle = \int_1^3 e^{-x}\,dx = 0.3181$$

$$\langle x,e^{-x}\rangle = \int_1^3 x\,e^{-x}\,dx = 0.5366$$

Portanto, o sistema de equações normais é dado por:

$$\begin{bmatrix} 1 & 4 \\ 4 & 8.6667 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 0.3181 \\ 0.5366 \end{bmatrix}$$

Usando o método de eliminação de Gauss, obtemos:

$a_1 = -0.0832$ $a_2 = 0.1003$ e a reta que melhor se ajusta à $f(x) = e^{-x}$ no intervalo [1, 3] é dada por:

$$g(x) = a_1 + a_2 x = -0.0832x + 0.1003$$